

# Rozpoznawanie znaków drogowych

Na podstawie sieci neuronowych

Merski Szymon

Czerwiec 2022

## Spis treści

<b>1</b>	<b>Wstęp</b>	<b>2</b>
1.1	Przykładowe znaki . . . . .	2
<b>2</b>	<b>Przedstawienie różnych modeli</b>	<b>3</b>
2.1	Model 1 . . . . .	3
2.2	Model 2 . . . . .	3
2.3	Model 3 . . . . .	3
2.4	Model 4 . . . . .	4
<b>3</b>	<b>Porównanie modeli</b>	<b>5</b>
3.1	Czasy . . . . .	5
3.2	Dokładność . . . . .	5
<b>4</b>	<b>Dodatkowe podejście</b>	<b>6</b>
4.1	Czas . . . . .	6
4.2	Dokładność . . . . .	6
<b>5</b>	<b>Podsumowanie</b>	<b>8</b>
<b>6</b>	<b>Źródła</b>	<b>8</b>

# 1 Wstęp

Stworzenie, wyuczenie oraz porównanie różnych konwolucyjnych sieci neuronowych, których zadaniem było rozpoznanie znaków drogowych

## 1.1 Przykładowe znaki



[Pełna baza zdjęć](#)

## 2 Przedstawienie różnych modeli

Każdy model został przetrenowany na 20 epokach, przy wielkości obrazu  $100 \times 100$ .

### 2.1 Model 1

Model składa się z następujących warstw:

```
model = models.Sequential()
model.add(layers.Rescaling(1./255))
model.add(layers.Conv2D(128, (3, 3), activation='relu', input_shape=(image_size, image_size, 3)))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(128, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(256, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Flatten())
model.add(layers.Dense(64, activation = 'relu'))
model.add(layers.Dropout(0.2))
model.add(layers.Dense(128, activation = 'relu'))
model.add(layers.Dense(len(test_labels), activation = 'softmax'))
```

### 2.2 Model 2

Model składa się z następujących warstw:

```
model = models.Sequential()
model.add(layers.Rescaling(1./255))
model.add(layers.Conv2D(128, (3, 3), activation='relu', input_shape=(image_size, image_size, 3)))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(128, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(256, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Flatten())
model.add(layers.Dense(64, activation = 'relu'))
model.add(layers.Dropout(0.2))
model.add(layers.Dense(128, activation = 'relu'))
model.add(layers.Dense(len(test_labels), activation = 'softmax'))
```

### 2.3 Model 3

Model składa się z następujących warstw:

```

model = models.Sequential()
model.add(layers.Conv2D(128, (3, 3), activation='relu', input_shape=(image_size, image_size, 3)))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(256, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Flatten())
model.add(layers.Dense(64, activation = 'relu'))
model.add(layers.Dropout(0.2))
model.add(layers.Dense(128, activation = 'relu'))
model.add(layers.Dense(len(test_labels), activation = 'softmax'))

```

## 2.4 Model 4

Model składa się z następujących warstw:

```

model = models.Sequential()
model.add(layers.Conv2D(128, (3, 3), activation='relu', input_shape=(image_size, image_size, 3)))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Conv2D(256, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

model.add(layers.Flatten())
model.add(layers.Dense(64, activation = 'relu'))
model.add(layers.Dropout(0.2))

model.add(layers.Dense(128, activation = 'relu'))
model.add(layers.Dense(len(test_labels), activation = 'softmax'))

```

### 3 Porównanie modeli


Przy porównaniu modeli zostało wzięte pod uwagę jak długo dany model się uczył oraz dokładność przy rozpoznaniu zdjęć.

#### 3.1 Czasy

Ilość epok: 20

model 1	123.7733s
model 2	124.8371s
model 3	120.1058s
model 4	127.1615s

#### 3.2 Dokładność




## 4 Dodatkowe podejście

Ten model znacznie różni się od pozostałych. Przed trenowaniem modelu obrazy zostały zmienione w binarne (czarno-białe). Czas oraz dokładność został mierzony przy takiej samej liczbie epok (20), co przyniosło następujące skutki:


### 4.1 Czas

extra model	129.9953s
-------------	-----------

### 4.2 Dokładność



Żeby osiągnąć przyzwoitą dokładność, trzeba było sieć uczyć przez ponad 50 epok.



## 5 Podsumowanie

Modele 1,2,3 osiągnęły bardzo podobne wyniki dokładności, po 20 epokach. Model 4 znacząco odstaje w zestawieniu dokładności, jak również w przypadku czasu potrzebnego do przetrenowania sieci.

Model dodatkowy został zdeklasyfikowany ze względu na jego niewydajność oraz skuteczność.

## 6 Źródła

- [Dane](#)
- [TensorFlow CNN](#)